VAE 与 UNet 速览

> 从两个独立技术，到扩散模型的骨架

配套课程：COMP 4423 Easy Computer Vision（PolyU）
本讲对应位置：L11 p20-23（VAE）、L10 p21-23（UNet）、L11 阅读清单（扩散模型）
参考实现：cs231n-2026 Assignment 3（`unet.py`、`gaussian_diffusion.py`、`DDPM.ipynb`）

一句话结论：VAE 教的是「怎么让网络学会一个可以采样的分布」，UNet 教的是「怎么在保留空间细节的前提下把特征压下去再升回来」。扩散模型（DDPM）恰好把这两件事缝在一起——它用一个 UNet 去预测噪声，用一系列正态分布的条件概率做逐步去噪；而它的整套数学语言（变分下界、后验分布、重参数化）与 VAE 同源。

阅读建议：先读 §1 建立直觉与对照，再按需要读 §2（VAE）或 §3（UNet），最后**必须**读 §4——联系与扩散模型的关系，才是这两项技术在 2026 年的真正价值所在。

目录

- 0　三分钟地图
- 1　前置：自编码器（AE）
- 2　VAE：给隐空间装上正态分布
- 3　UNet：为「定位」而生的 U 形结构
- 4　联系：它们如何在扩散模型里合体
- 5　对照 COMP 4423：考点提示与覆盖缺口
- 6　术语速查表
- 7　参考文献与延伸阅读

0　三分钟地图：它们是什么，为什么放在一起讲

	VAE（变分自编码器）	**UNet（U 型网络）**
出身	生成模型 / 表示学习（Kingma & Welling, 2014）	分割网络（Ronneberger et al., 2015，医学图像分割）
核心问题	如何学到一个可采样、可生成的隐变量分布	如何在低分辨率语义与高分辨率定位之间取得平衡
关键机制	重参数化（reparameterization）、变分下界 ELBO	跳跃连接（skip connection）、编码器-解码器对称结构
输入 → 输出	图像 → 隐变量 z（均值+方差）→ 重建图像	图像 → 同尺寸的逐像素预测（分割掩码）
在 4423 的位置	L11 p20-23，4 页，点到 reparameterization 为止	L10 p21-23，3 页，纯结构描述
在扩散模型中的角色	提供变分框架与「隐空间」思想；潜在扩散的压缩器	提供去噪网络的骨干架构（backbone）

三个容易混淆的点，先说清楚：

1. **VAE 不是「压缩」，是「建模分布」。** 普通自编码器（AE）只是一个确定性的压缩-还原器，你随便从隐空间抽一个点，解码出来大概率是垃圾。VAE 强制隐空间服从正态分布，从而让「采样」变得有意义。
2. **UNet 最初不是为了生成，而是为了分割。** 它的「U 形」是为了解决分割任务里「既要类别语义、又要像素级边界」的矛盾。今天它更出名的身份反而是扩散模型的去噪器。
3. **两者在扩散模型里是「骨架 + 数学」的关系，不是并列关系。** UNet 是工程结构，VAE 是概率建模思路。DDPM 借用了后者的问题形式、前者的网络结构。

1　前置：自编码器（AE）

要理解 VAE，必须先看清 AE 缺了什么。

1.1　结构

自编码器是一个「自监督」的瓶颈结构：

```
输入 x  ⟶  Encoder  ⟶  隐向量 z  ⟶  Decoder  ⟶  重建 x̂
```

- **Encoder**：把高维输入压成低维瓶颈向量 z（降维、抽特征）。
- **Decoder**：从 z 还原出 $\hat{x}$，目标是让 $\hat{x} \approx x$。
- **损失**：重建误差，通常就是 MSE 或 BCE。
- **监督信号从哪来**：标签就是输入自己（所以叫自监督）。

> **常见应用**：去噪、超分、异常检测（重建误差大 = 异常）、数据压缩，以及作为预训练的特征提取器。

1.2　AE 的致命缺陷：隐空间没有被约束

AE 只被要求「重建得准」，没有任何一项损失去规定 z 的分布形状。于是：

- 隐空间里绝大多数位置是「没被训练过的荒漠」，解码出来是噪声或乱码；
- 不同样本的 z 可以散落得毫无规律，点与点之间没有平滑的语义过渡；
- **结论**：AE 是一个好的压缩器，不是一个好的生成模型——它不能「随机采样出一个新样本」。

VAE 的全部动机，就是修掉这一条。

2　VAE：给隐空间装上正态分布

2.1　核心思路（对应 L11 p20）

课件原文的表述非常精炼，值得逐句拆开：

> *"In the training step, the input data is compressed into a vector of low dimensional normal distribution by the encoder, and the vector is reconstructed into the input data by the decoder. In the generation step, a vector of normal distribution is randomly sampled and input into the decoder to generate data."*
> —— 课件 L11 p20

翻译成流程：

1. **训练阶段**：$x \to$ Encoder $\to$ 一个低维正态分布 $\to$ 采样出 $z \to$ Decoder $\to \hat{x}$，用重建误差训练。
2. **生成阶段**：直接从标准正态 $\mathcal{N}(0, I)$ 随机采样一个 $z \to$ Decoder $\to$ 一张新图。

关键转变：隐空间从一个「随便什么形状」的点集，变成了一个被规定好的正态分布。这样采样才有意义——从 $\mathcal{N}(0, I)$ 里抽点，抽到的一定是「有意义的区域」。

2.2 重参数化（Reparameterization）—— 4423 唯一展开讲的机制

课件 L11 p22 的原文（这是整个 VAE 部分最有信息量的一段）：

> *"In fact, the output of VAE encoder is not a vector, but two values, which represent the mean and variance of a normal distribution, respectively. Once learned, the parameters can be used to modify a vector E that follows the standard normal distribution N(0,1) by adding the mean values and multiplying by the variance. ... This process is called reparameterization, which avoids the situation that the sampling is non differentiable (we cannot calculate the gradients in this case)."*
> —— 课件 L11 p22

拆成两步：

1. **编码器输出两个向量，而不是一个。** 分别是均值 μ 和方差 σ^2（工程上通常输出 $\log \sigma^2$，保证非负且数值稳定）。
2. **从标准正态采样再变换**，而不是直接从 $\mathcal{N}(\mu, \sigma^2)$ 采样。这一步就是重参数化。

$$z = \mu + \sigma \odot \varepsilon, \qquad \varepsilon \sim \mathcal{N}(0, I)$$

> **为什么必须这么写？（考试爱问）**
> 「直接从 $\mathcal{N}(\mu, \sigma^2)$ 采样」这个动作本身是随机的，梯度无法穿过随机采样节点回传到编码器，网络训不起来。重参数化把随机性「外移」到与参数无关的 ε 上，于是 z 对 μ 和 σ 可导：$\frac{\partial z}{\partial \mu} = 1$，$\frac{\partial z}{\partial \sigma} = \varepsilon$。梯度可以正常反传。

2.3 损失函数：重建 + 正则

VAE 的损失由两项组成，这两项的对抗关系是理解 VAE 生成质量的钥匙：

$$L = L_{\text{recon}} + L_{\text{KL}}$$

- L_{recon} **（重建损失）**：MSE 或 BCE，负责「生成得像」。
- L_{KL} **（KL 散度正则）**：把编码器输出的分布往 $\mathcal{N}(0, I)$ 上拉，负责「隐空间规整、可采样」。两个正态分布之间的 KL 有闭式解：

$$\mathrm{KL}\big(\mathcal{N}(\mu, \sigma^2) \,\|\, \mathcal{N}(0, 1)\big) = -\tfrac{1}{2} \sum \big(1 + \log \sigma^2 - \mu^2 - \sigma^2\big)$$

理论上这一项来自变分下界（ELBO）。对本课程来说，只要记住结论：**最大化 ELBO = 最大化「重建的对数似然」+ 最小化「近似后验与先验的 KL」**，前者对应重建项，后者对应 KL 项。

完整推导（超出 4423 范围，但值得知道它存在）：

$$\log p(x) \;\geq\; \mathbb{E}_{q(z|x)}\big[\log p(x \mid z)\big] - \mathrm{KL}\big(q(z \mid x) \,\|\, p(z)\big)$$

左边是数据对数似然（不可直接算），右边是 ELBO（可算，最大化它即间接最大化似然）。

2.4 权衡：重建质量 vs 隐空间规整

两项损失互相拉扯，这个张力是 VAE 最有意思的地方：

- **KL 项太强** → 隐空间非常规整，但编码器干脆忽略输入，所有样本都编码成同一个 $\mathcal{N}(0, I)$。这叫**后验坍塌（posterior collapse）**，重建模糊、生成多样性差。
- **KL 项太弱** → 退化成普通 AE，重建清晰但隐空间不可采样，生成能力丧失。

这解释了 VAE 的典型观感：**生成的图偏模糊、偏「平均脸」**。因为每一项损失都要求它别太极端，模型倾向于输出所有可能结果的均值。

2.5 一句话对比 AE / VAE

维度	AE	VAE
隐空间形状	任意、无约束	强制接近 $\mathcal{N}(0, I)$
编码器输出	一个向量 z	两个向量 μ 和 σ^2
能否采样生成	基本不能	能（从 $\mathcal{N}(0, I)$ 采样）
损失	只有重建误差	重建误差 + KL 正则
生成质量	—（不生成）	偏模糊，但语义插值平滑
本课程覆盖	未单独讲	L11 p20-23

---

3 UNet：为「定位」而生的 U 形结构

3.1 动机：分割任务的两难（对应 L10 p21）

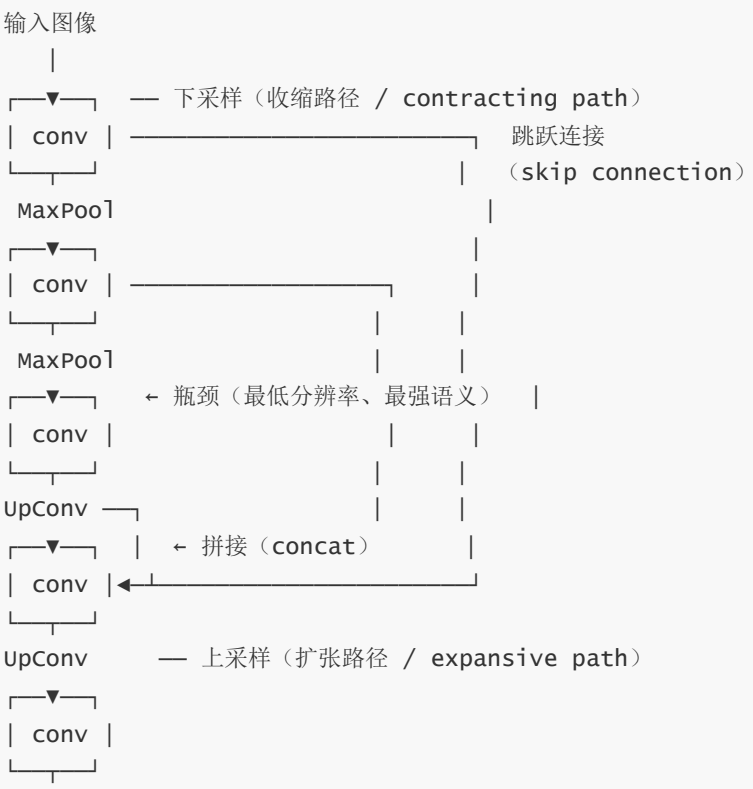
图像分类只需要一个标签，但语义分割需要对**每一个像素**给出类别。这就产生了矛盾：

- **深层特征**：语义强（知道「这是细胞」），但分辨率低（经过多次下采样，位置信息糊了）。
- **浅层特征**：分辨率高（知道「边界在哪」），但语义弱（不知道这块是什么东西）。

UNet 的设计目标就是同时拿到这两者。

> *"The U-Net architecture stems from the so-called fully convolutional network, which is designed to solve the problem of medical image segmentation. The U-Net means that the left part of U is a down-sapling, and the right part of U is an upsampling, which gives it the u-shaped architecture."*
> —— 课件 L10 p21（原稿 `down-sapling` 为 `down-sampling` 笔误）

3.2 结构：下采样 → 瓶颈 → 上采样 + 跳跃连接



▼
分割掩码（与输入同尺寸）

三个关键部件：

1. **下采样 / 收缩路径**：重复「卷积 → ReLU → 最大池化」。空间尺寸减半、通道数翻倍。
2. **上采样 / 扩张路径**：反卷积（up-convolution）把分辨率升回去，通道数减半。
3. **跳跃连接**：把左侧同分辨率的特征图与右侧**拼接**（concatenation）。这是 UNet 的灵魂。

> *"During the down-sampling, the spatial information is reduced while the feature information is increased. The upsampling combines the feature and spatial information through a sequence of up-convolutions and concatenations with high-resolution features from the left."*
> —— 课件 L10 p22

3.3 为什么跳跃连接是关键

下采样过程中，**位置信息**被逐渐丢弃（池化不可逆地丢掉了精确坐标）。上采样要靠自己猜回边界，很难。跳跃连接相当于给上采样路径「直接快递一份原始高分辨率特征」——它不需要重新发明边缘，只需要学会「把语义标签贴到这些现成的边缘上」。

这是编码器-解码器（encoder-decoder）架构的通用范式：**编码器负责「是什么」，解码器负责「在哪里」，跳跃连接负责把两者对齐。**

3.4 从分割到生成：UNet 的「通用去噪器」形态

cs231n 参考实现中的 UNet（`cs231n/unet.py`）已经是为扩散模型改造过的版本，与 2015 原版有几处重要差异：

部件	2015 原版 UNet（分割）	扩散用 UNet（cs231n 参考实现）
输入	图像	噪声图 x_t + 时间步 t + 文本嵌入
下采样	MaxPool + 卷积	`stride=2` 卷积（`Downsample`）
上采样	反卷积	双线性插值 + 3×3 卷积（`Upsample`）
基本块	Conv-ReLU 堆叠	`ResnetBlock`（残差连接 + `RMSNorm` + GELU + Dropout）
条件注入	无	时间步经正弦位置编码 + MLP，对特征做 scale-shift 调制
文本条件	无	`condition_mlp` 编码文本嵌入，与时间上下文相加
输出	C 类分割掩码	与输入同通道数的噪声预测 ε_θ

值得注意的细节：

- **时间步编码用 sinusoidal position embedding**（`unet.py` 的 `SinusoidalPosEmb`），和 Transformer 的位置编码同源，让网络知道「现在噪声有多重」。
- **条件通过 scale-shift 调制融入**（`Block.forward` 中的 `x * (scale + 1) + shift`），比简单相加更能控制特征。
- **跳跃连接照旧保留**：上采样路径拼接下采样特征，所以 `ResnetBlock` 的输入通道是 2×（见 `unet.py` 中关于 skip connection 的注释）。
- **无条件训练**：训练时以 `uncond_prob`（默认 0.2）随机丢弃文本条件，以支持推理时的 classifier-free guidance。

4　联系：它们如何在扩散模型里合体

这是全篇最重要的一节。前面两节是两个孤立的技术，这一节解释它们为什么值得放在一起学。

4.1　DDPM 的两句话概括

扩散模型（DDPM, Ho et al. 2020）的思路可以用两个过程概括：

1. **前向过程（加噪）**：对一张干净图 x_0，逐步加一点点高斯噪声，共 T 步（通常 $T = 1000$），最后变成纯噪声 $x_T \sim \mathcal{N}(0, I)$。**这一步不需要学习。**
2. **反向过程（去噪）**：训练一个网络，从 x_T 出发一步步去噪，恢复出 x_0。**这一步需要学习，而这个网络就是 UNet。**

前向过程有个漂亮的性质：可以一步到位算任意时刻的 x_t（$\bar{\alpha}_t$ 是噪声调度的累积乘积）：

$$x_t = \sqrt{\bar{\alpha}_t}\, x_0 + \sqrt{1 - \bar{\alpha}_t}\, \varepsilon, \qquad \varepsilon \sim \mathcal{N}(0, I)$$

4.2　UNet 在这里干什么

DDPM 的训练目标极其简单——简单到有点反直觉：

$$L = \mathbb{E}_{t,\, x_0,\, \varepsilon}\Big[\big\| \varepsilon - \varepsilon_\theta\big(\sqrt{\bar{\alpha}_t}\, x_0 + \sqrt{1 - \bar{\alpha}_t}\, \varepsilon,\ t\big) \big\|^2 \Big]$$

网络 ε_θ 的唯一任务是：**看着一张加噪图 x_t 和时间步 t，猜出当初加进去的噪声 ε。**

为什么这需要 UNet?

- **输出必须和输入同尺寸**（噪声图进、噪声图出）。这正是 UNet 作为编码器-解码器结构的天生能力。
- **既要全局语义又要像素级精度**：去噪时，网络既要理解「这是什么物体」（决定整体结构），又要精确还原纹理细节。这与分割任务的矛盾完全一致——所以跳跃连接在这里同样不可或缺。
- **必须能区分不同噪声强度**：t 小的时候需要精修细节，t 大的时候需要决定整体构图。时间步条件（sinusoidal 编码）就是干这个的。
- **必须能接受条件输入**：文生图需要文本条件，通过 `condition_mlp` 注入（并配合 classifier-free guidance）。

> **一句话**：UNet 在扩散模型里不是「顺便用一下」，而是被选中作为「图像到图像、多尺度、带条件的回归器」的最优解。它是扩散模型的骨架（backbone），换掉它整个模型就跑不动。

4.3　VAE 在哪里？—— 三个层次的联系

这一层联系比 UNet 更隐蔽，但更本质。分三个层次看。

层次一：数学框架同源（变分推断）

DDPM 的原始论文标题就是 *"Denoising Diffusion Probabilistic Models"*，其推导建立在与 VAE 完全相同的变分下界（ELBO）之上：

$$\log p(x_0) \ \geq\ \mathbb{E}\big[\log p_\theta(x_0 \mid \cdots)\big] - \mathrm{KL}\big(q(x_{1:T} \mid x_0) \,\|\, p_\theta(x_{1:T})\big)$$

区别在于：

- VAE 的隐变量是**单步**的 z（维度通常更低，是压缩）；
- 扩散模型的隐变量是**整个噪声序列** $x_1 \dots x_T$（维度与图像相同，是逐步加噪）；
- DDPM 因此可以看作一个**层级 VAE（hierarchical VAE）**，且编码器（前向加噪过程）被固定为高斯加噪、不需要学习——这正是它比 VAE 好训的原因。

层次二：反向过程用的正是「正态分布 + 重参数化」

DDPM 的每一步反向去噪都写成条件高斯：

$$p_\theta(x_{t-1} \mid x_t) = \mathcal{N}\big(x_{t-1};\ \mu_\theta(x_t, t),\ \Sigma_\theta(x_t, t)\big)$$

而实际采样时需要从这个高斯采样——用的还是 VAE 那一招：

$$x_{t-1} = \mu_\theta(x_t, t) + \sigma_t \odot \varepsilon, \qquad \varepsilon \sim \mathcal{N}(0, I)$$

在参考实现里，`gaussian_diffusion.py` 的 `q_posterior()` 与 `p_sample()` 就是这一段：先算后验均值（`posterior_mean_coef1 * x_start + posterior_mean_coef2 * x_t`），再加 $\sigma \cdot \varepsilon$ 采样。没有重参数化，这一步同样无法反传。

> **对应关系**：VAE 的 $z = \mu + \sigma \odot \varepsilon$ ↔ DDPM 的 $x_{t-1} = \mu_\theta + \sigma_t \odot \varepsilon$。同一个技巧，一个用在隐空间采样，一个用在时间步之间采样。

层次三：像素空间 vs 隐空间（Latent Diffusion）

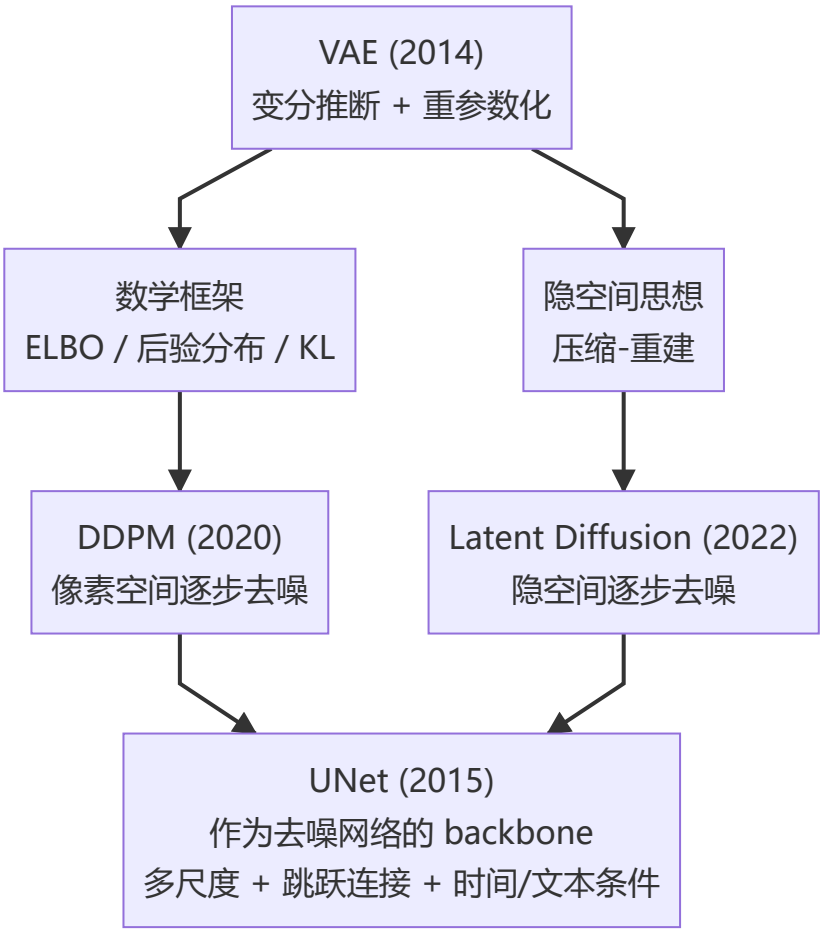
这一层是最直接的工程联系，也是今天实际的主流做法（Stable Diffusion）：

- **DDPM（原始）**：直接在 $512 \times 512 \times 3$ 的像素上做扩散。计算量巨大，训练贵、采样慢。
- **Latent Diffusion（LDM / Stable Diffusion）**：先用一个 VAE 把图像压到低维隐空间（如 $64 \times 64 \times 4$，压缩约 48 倍），**在隐空间里做扩散**，最后用 VAE 解码器升回像素。

于是 VAE 在扩散模型里有了两个截然不同的身份：

1. **在 LDM 里，VAE 是压缩器**——负责图像与隐空间的双向转换，扩散只在隐空间发生。这里的 VAE 甚至不需要生成得好看，只需要重建准、隐空间平滑。
2. **在整个扩散范式中，VAE 是思想来源**——提供了「用变分下界训练生成模型」「用重参数化让随机采样可导」「把生成建模为隐变量到观测的映射」这三件事。

4.4　一张图理清三者关系



（若你的 Markdown 预览器不支持 Mermaid，等价文字版见上方各小节。）

4.5 横向对比：AE / VAE / GAN / 扩散

	AE	VAE	GAN	扩散模型（DDPM）
核心机制	压缩-重建	变分推断 + 重参数化	生成器-判别器博弈	逐步加噪-去噪
损失	重建误差	重建 + KL	对抗损失（min-max）	噪声预测的 MSE
训练稳定性	稳定	稳定	不稳定（模式坍塌）	稳定
生成质量	不能生成	偏模糊	锐利但易崩	最佳（采样慢）
采样速度	—	一次前向	一次前向	T 次（约 1000 步）
本课程覆盖	未单独讲	L11 p20-23	L11 p24-28	仅阅读清单提到

5 对照 COMP 4423：考点提示与覆盖缺口

5.1 课件覆盖情况

主题	位置	覆盖程度	说明
VAE 基本流程	L11 p20	✅ 完整	训练/生成两阶段有明确文字描述
重参数化	L11 p22	✅ 完整	唯一展开讲的 VAE 机制，含「为什么需要」的解释

主题	位置	覆盖程度	说明
VAE 应用举例	L11 p23	✅ 完整	图像生成、符号音乐生成（Muse Morphose）
VAE 损失函数 / ELBO	—	✗ 无	全篇 12 份讲义零命中，需自行补（见 §2.3）
KL 散度公式	—	✗ 无	同上
UNet 结构描述	L10 p21-22	✅ 完整	下采样/上采样/跳跃连接均有文字
跳跃连接的原理	L10 p22	○ 偏薄	只说「拼接高分辨率特征」，未讲为什么重要
UNet 原论文公式	—	✗ 无	p23 疑似纯图页，无文字可提取
扩散模型	L11 阅读清单	○ 仅点名	正文无内容，本文 §4 为补充
VAE/UNet 在扩散中的角色	—	✗ 无	课程未讲，本文 §4 为补充

5.2 可能的考法（按课件文字可考程度排序）

1. **名词解释 / 流程描述**：什么是 VAE？训练阶段和生成阶段分别做什么？（L11 p20 有完整原文可背）
2. **简答：为什么需要重参数化**：因为直接采样不可导，梯度无法回传（L11 p22 明确给了这个理由，几乎必考）。
3. **简答：VAE 编码器输出的是什么**：不是向量，而是均值与方差两个值（L11 p22 原句）。
4. **画图题：UNet 结构**：画出 U 形结构，标注下采样、上采样、跳跃连接（L10 p21-22）。
5. **简答：UNet 的下采样/上采样各有什么作用**：下采样降低空间信息、增加特征信息；上采样结合特征与空间信息（L10 p22 原文可直接引用）。

5.3 必须自己补的部分

- **VAE 的损失函数**：至少记住 $L = L_{\text{recon}} + L_{\text{KL}}$，以及 KL 项在把隐空间拉向标准正态。
- **UNet 与扩散模型的结合方式**：课程完全没讲，但这是这两项技术在 2026 年最主要的存在形式（见 §4.2）。
- **扩散模型基础**：了解前向加噪公式与噪声预测目标即可，重点理解「UNet 在其中扮演去噪器」这一层关系。

---

6 术语速查表

术语	英文	一句话解释
自编码器	Autoencoder (AE)	编码器压缩 + 解码器还原，只优化重建误差
变分自编码器	Variational AE (VAE)	强制隐空间服从正态分布，从而可以采样生成
隐变量	latent variable (z)	低维的、被建模为分布的中间表示
重参数化	reparameterization	$z = \mu + \sigma \odot \varepsilon$，把随机性外移使采样可导
变分下界	ELBO	对数似然的可计算下界，最大化它即间接最大化似然
KL 散度	KL divergence	两个分布的差异度量，VAE 用它约束隐空间
后验坍塌	posterior collapse	KL 项过强时编码器忽略输入、隐空间退化的现象
跳跃连接	skip connection	把编码器的高分辨率特征直接送到解码器同级

术语	英文	一句话解释
收缩/扩张路径	contracting / expansive path	UNet 左半（下采样）与右半（上采样）
反卷积	up-convolution	把特征图分辨率放大的操作
前向过程	forward process	逐步加噪 $x_0 \to x_T$，无需学习
反向过程	reverse process	逐步去噪 $x_T \to x_0$，由 UNet 学习
噪声调度	noise schedule (β_t / $\bar{\alpha}_t$)	控制每步加多少噪声的系数序列
无分类器引导	classifier-free guidance	训练时随机丢条件，推理时放大条件影响
潜在扩散	Latent Diffusion (LDM)	在 VAE 隐空间而非像素空间做扩散

7　参考文献与延伸阅读

- **VAE 原始论文**：Kingma & Welling, *Auto-Encoding Variational Bayes*, 2014（课件 L11 p20 引用）
- **UNet 原始论文**：Ronneberger, Fischer & Brox, *U-Net: Convolutional Networks for Biomedical Image Segmentation*, 2015（课件 L10 p21 引用）
- **GAN**：Goodfellow et al., *Generative Adversarial Networks*, 2014（课件 L11 p24-28）
- **DDPM**：Ho, Jain & Abbeel, *Denoising Diffusion Probabilistic Models*, 2020
- **潜在扩散**：Rombach et al., *High-Resolution Image Synthesis with Latent Diffusion Models*, 2022
- **无分类器引导**：Ho & Salimans, *Classifier-Free Diffusion Guidance*, 2022（cs231n 参考实现引用）
- **教程**：*Understanding Variational Autoencoders*（课件 L11 p20 给出的 towardsdatascience 链接）

本文基于课程课件（L10 p21-23、L11 p20-23）与 cs231n 2026 Assignment 3 参考实现整理。§2.3 的损失函数、§4 的全部内容为课件未覆盖、由通用文献补充，以便建立完整图景。