10 扩散模型：从噪声中生成图像

10.1 DDPM 理论框架

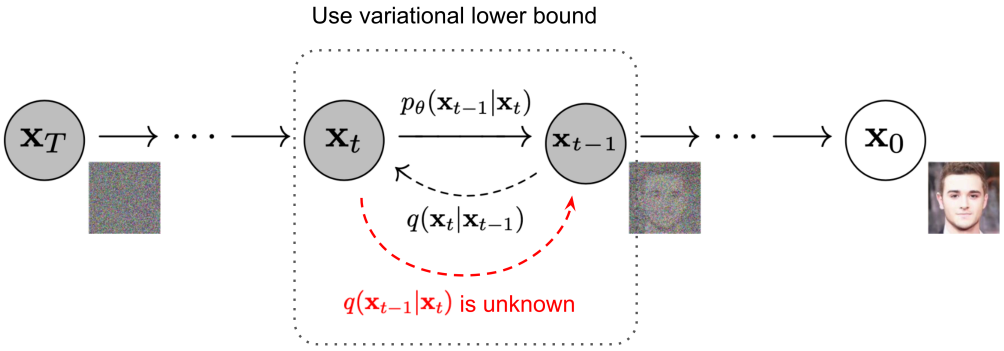


图 7　DDPM 前向与反向过程：前向过程逐步加噪直到纯高斯噪声，反向过程通过学习去噪逐步恢复原始图像。

Denoising Diffusion Probabilistic Models 定义了一个从数据逐步加噪到纯噪声的马尔可夫链。

前向过程（加噪）：

$$q(x_t \mid x_0) = \mathcal{N}\left(x_t; \sqrt{\bar{\alpha}_t} x_0, (1-\bar{\alpha}_t) I\right) \tag{43}$$

即 $x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1-\bar{\alpha}_t}\varepsilon$，其中 $\varepsilon \sim \mathcal{N}(0, I)$。

```
def q_sample(self, x_start, t, noise):
    sqrt_alpha_bar = extract(self.sqrt_alphas_cumprod, t, x_start.shape)
    sqrt_one_minus = extract(self.sqrt_one_minus_alphas_cumprod, t, x_start.shape)
    return sqrt_alpha_bar * x_start + sqrt_one_minus * noise
```

反向过程（去噪）的后验分布：

$$q(x_{t-1} \mid x_t, x_0) = \mathcal{N}(x_{t-1}; \tilde{\mu}_t, \tilde{\sigma}_t^2 I) \tag{44}$$

其中 $\tilde{\mu}_t = \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1-\bar{\alpha}_t} x_0 + \frac{\sqrt{\alpha_t}(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t} x_t$。

训练目标简化为预测噪声：

$$L = \mathbb{E}_{t, x_0, \varepsilon}\left[\left\|\varepsilon - \varepsilon_{\theta(x_t, t)}\right\|^2\right] \tag{45}$$

```
def p_losses(self, x_start, model_kwargs={}):
    t = torch.randint(0, nts, (b,), device=x_start.device).long()
    noise = torch.randn_like(x_start)
    x_t = self.q_sample(x_start, t, noise)
    model_pred = self.model(x_t, t, model_kwargs=model_kwargs)
    loss = F.mse_loss(model_pred, noise, reduction="none")
    loss = (loss * loss_weight).mean()
```

10.2 U-Net 架构

噪声预测网络使用 U-Net 结构：

- **下采样路径**：逐步缩小空间分辨率，增加通道数
- **上采样路径**：逐步恢复分辨率，通过跳连接（skip connections）融合高分辨率特征

- **时间嵌入**：使用正弦位置编码将时间步 t 嵌入为向量，通过 FiLM 调制（scale + shift）注入每个 ResNet Block
- **Classifier-Free Guidance**：训练时以概率 p 随机丢弃条件信息，推理时通过加权有条件和无条件预测的差值来增强条件控制

10.3 噪声调度

实现了三种 β 调度策略：

调度方式	特点
Linear	原始 DDPM 论文提出，β 线性增长
Cosine	改善 SNR 分布，避免后期信息过早丢失
Sigmoid	适合高分辨率图像（$>$ 64×64）