Diffusion model (一)
(DDPM原理)

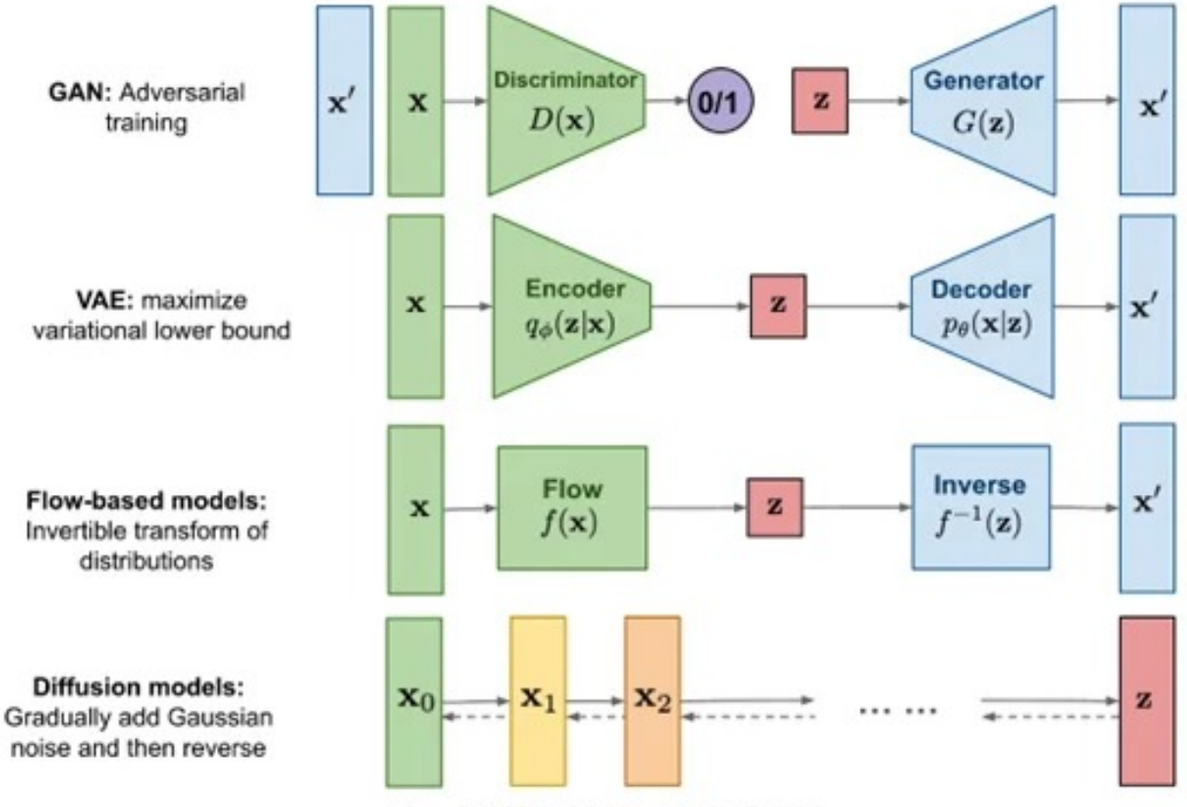
个人学习使用

2025年9月

1.背景

➢ 基于文本用AI生成图像

生成神经网络主要包含四种模型，分别是生成对抗网络（GAN），变分自编码器（VAE），标准化流模型（NF）以及扩散模型（DM）。扩散模型的算法理论基础是通过变分推断训练参数化的马尔可夫链，它在许多任务上展现了超过GAN等其它模型的效果，已经被应用在DALL-E 2，stable-diffusion和Imagen等主流模型。



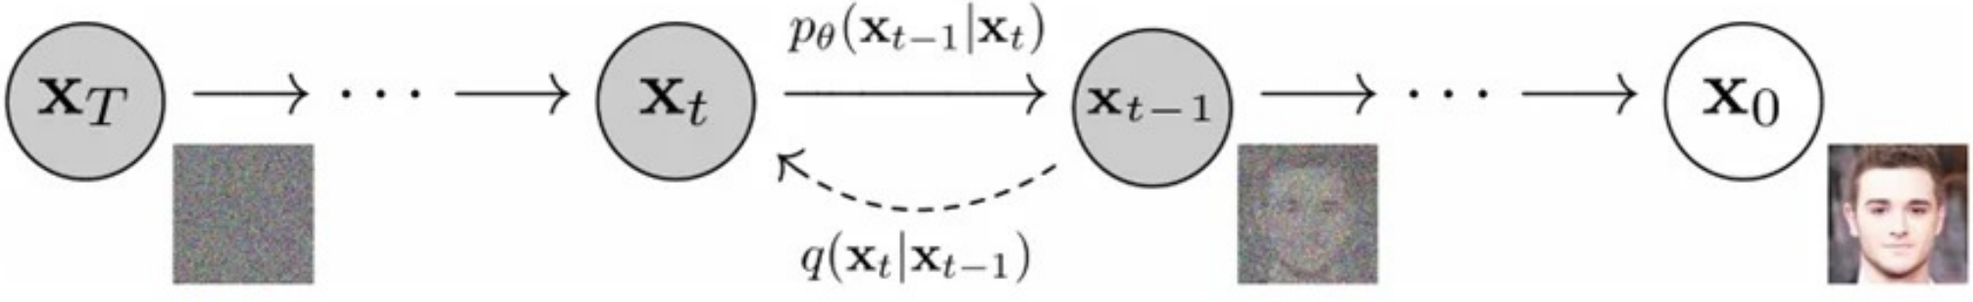
生成模型的四种类型

2. 扩散模型原理

➢ 扩散模型的两个过程

扩散模型包括两个过程：前向过程（forward process）和反向过程（reverse process），其中前向过程又称为扩散过程（diffusion process），如下图所示。

无论是前向过程还是反向过程都是一个参数化的马尔可夫链（Markov chain），其中反向过程可以用来生成数据，这里我们将通过变分推断来进行建模和求解。



扩散模型示意图

- **Diffusion model**
  - **前向：逐步加噪，最后让图片变成噪声**
  - **反向：预测噪声，逐步去噪，生成图片**

2. 扩散模型原理

➢ 扩散过程

– Diffusion model

- 前向：x_0到x_T为逐步加噪的前向过程，从原始图片逐步加噪至纯噪声。

1. **给定真实数据样本 $x_0 \sim q(x_0)$，逐步加噪**
2. **通过以下公式进行采样得到x_t时刻的分布**

$$x_t = \sqrt{\alpha_t} x_{t-1} + \sqrt{1-\alpha_t}\epsilon \qquad \epsilon \sim \mathcal{N}(0, \boldsymbol{I})$$

$$\alpha_t = 1 - \beta_t$$

还可以表示为

$$q(x_t \mid x_{t-1}) = \mathcal{N}(x_t; \sqrt{\alpha_t} x_{t-1}, (1-\alpha_t)I) \quad t = 1, \ldots, T$$

β_t是系数，越来越大，从0.0001到0.002（每次加的噪声越来越大）

（这里使用α_t，如果用β_t表示，公式(3)不容易化简）

接下来，计算任意时刻x_t关于x_0的关系，首先看x_{t-2}和x_t的关系

2. 扩散模型原理

➢ 扩散过程

3. 首先看x_{t-2}和x_t的关系

$$x_{t-1} = \sqrt{\alpha_{t-1}}x_{t-2} + \sqrt{1-\alpha_{t-1}}\epsilon_{t-1} \quad (1)$$

$$x_t = \sqrt{\alpha_t}x_{t-1} + \sqrt{1-\alpha_t}\epsilon_t \quad (2)$$

将(1)式代入(2)式，得

$$x_t = \sqrt{\alpha_t}\sqrt{\alpha_{t-1}}x_{t-2} + \sqrt{\alpha_t}\sqrt{1-\alpha_{t-1}}\epsilon_{t-1} + \sqrt{1-\alpha_t}\epsilon_t \quad (3)$$

因为ϵ_{t-1}和ϵ_t都服从高斯分布 $\epsilon \sim \mathcal{N}(0, \boldsymbol{I})$

$$z = \sqrt{\alpha_t}\sqrt{1-\alpha_{t-1}}\epsilon_{t-1} + \sqrt{1-\alpha_t}\epsilon_t \Rightarrow \ z \sim \mathcal{N}(0, (\alpha_t(1-\alpha_{t-1}) + (1-\alpha_t))\boldsymbol{I})$$

有 $\epsilon_1 \sim \mathcal{N}(\mu_1, \sigma_1^2\boldsymbol{I})$，$\epsilon_2 \sim \mathcal{N}(\mu_2, \sigma_2^2\boldsymbol{I})$ 得 $\epsilon = \epsilon_1 + \epsilon_2$，$\epsilon \sim \mathcal{N}(\mu_1 + \mu_2, (\sigma_1^2 + \sigma_2^2)\boldsymbol{I})$

因此(3)式可以转换为

$$x_t = \sqrt{\alpha_t}\sqrt{\alpha_{t-1}}x_{t-2} + \sqrt{(\alpha_t(1-\alpha_{t-1}) + (1-\alpha_t))}\check{\epsilon}_t$$

$\check{\epsilon}_t \sim \mathcal{N}(0, \boldsymbol{I})$ 上标只是为了区别ϵ_t

2. 扩散模型原理

➢ 扩散过程

3. 得到x_{t-2}和x_t的关系

$$x_t = \sqrt{\alpha_t}\sqrt{\alpha_{t-1}}x_{t-2} + \sqrt{\left(\alpha_t(1-\alpha_{t-1}) + (1-\alpha_t)\right)}\tilde{\epsilon}_t$$

$$= \sqrt{\alpha_t\alpha_{t-1}}x_{t-2} + \sqrt{(1-\alpha_t\alpha_{t-1})}\tilde{\epsilon}_t$$

$$= \sqrt{\bar{\alpha}_t}x_{t-2} + \sqrt{(1-\bar{\alpha}_t)}\tilde{\epsilon}_t \qquad where\ \bar{\alpha}_t = \alpha_t\alpha_{t-1}$$

4. 通过嵌套，可以得到任意时刻x_t关于x_0的关系

$$x_t = \sqrt{\dot{\alpha}_t}x_0 + \sqrt{(1-\dot{\alpha}_t)}\check{\epsilon}_t \qquad where\ \dot{\alpha}_t = \prod_{i=1}^{t}\alpha_i$$

$$i.e. \qquad q(x_t \mid x_0) = \mathcal{N}\left(x_t; \sqrt{\dot{\alpha}_t}x_0, (1-\dot{\alpha}_t)I\right) \quad t = 1, \dots, T$$

5. 当$t = T$时（前向最后一步）

$\dot{\alpha}_T = \prod_{i=1}^{T}\alpha_i$很小接近于0，所以

$$x_T \approx \sqrt{(1-\dot{\alpha}_T)}\check{\epsilon}_T \approx \check{\epsilon}_T$$

i.e. x_T几乎是一个标准高斯噪声向量，与原始数据x_0已经几乎没有关系。

得到任意时刻x_t关于x_0的计算公式后，一次性直接采样 x_t，不用把噪声一步一步加上去

2. 扩散模型原理

➢ 反向过程

– Diffusion model

- 反向：x_T到x_0为将一组随机噪声还原为输入的过程。该过程需要学习一个去噪过程，直到还原一张图片。

1. 从纯噪声$x_T \sim \mathcal{N}(0, I)$逐步去噪，恢复成数据分布
2. 反向过程，已知x_t求x_{t-1}，即$q(x_{t-1}|x_t)$

$$q(x_{t-1}|x_t) = q(x_t|x_{t-1})\frac{q(x_{t-1})}{q(x_t)} \quad \text{(贝叶斯公式)}$$

然而，$q(x_{t-1})$和$q(x_t)$未知，但是前向过程已知任意t时刻$q(x_t \mid x_0)$

3. 将求$q(x_{t-1}|x_t)$（不可解）准换为求$q(x_{t-1}|x_t, x_0)$（条件化，有闭式形式）

$$q(x_{t-1}|x_t, x_0) = q(x_t|x_{t-1}, x_0)\frac{q(x_{t-1}|x_0)}{q(x_t|x_0)} \quad (1)$$

求$q(x_{t-1}|x_t, x_0)$，即已知x_0和x_t求x_{t-1}的分布

2. 扩散模型原理

➢ 反向过程

4. 已知

$$q(x_{t-1}|x_0) = \sqrt{\bar{\alpha}_{t-1}}x_0 + \sqrt{(1-\bar{\alpha}_{t-1})}\tilde{\epsilon}_{t-1} \quad \sim \mathcal{N}\left(\sqrt{\bar{\alpha}_{t-1}}x_0, (1-\bar{\alpha}_{t-1})\boldsymbol{I}\right)$$

$$q(x_t|x_0) = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{(1-\bar{\alpha}_t)}\tilde{\epsilon}_t \quad \sim \mathcal{N}\left(\sqrt{\bar{\alpha}_t}x_0, (1-\bar{\alpha}_t)\boldsymbol{I}\right)$$

$$q(x_t|x_{t-1},\ x_0) = \sqrt{\alpha_t}x_0 + \sqrt{(1-\alpha_t)}\epsilon_t \quad \sim \mathcal{N}(\sqrt{\alpha_t}x_0, (1-\alpha_t)\boldsymbol{I})$$

高斯公式为：$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}}\exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$

公式(1)用高斯公式可以表示为

$$q(x_{t-1}|x_t,\ x_0) \propto \exp\left(-\frac{1}{2}\left(\frac{\left(x_t - \sqrt{\alpha_t}x_{t-1}\right)^2}{\beta_t} + \frac{\left(x_{t-1} - \sqrt{\bar{\alpha}_{t-1}}x_0\right)^2}{1-\bar{\alpha}_{t-1}} - \frac{\left(x_t - \sqrt{\bar{\alpha}_t}x_0\right)^2}{1-\bar{\alpha}_t}\right)\right)$$

$$= \exp\left(-\frac{1}{2}\left(\frac{x_t^2 - 2\sqrt{\alpha_t}x_t x_{t-1} + \alpha_t x_{t-1}^2}{\beta_t} + \frac{x_{t-1}^2 - 2\sqrt{\bar{\alpha}_{t-1}}x_0 x_{t-1} + \bar{\alpha}_{t-1}x_0^2}{1-\bar{\alpha}_{t-1}} - \frac{\left(x_t - \sqrt{\bar{\alpha}_t}x_0\right)^2}{1-\bar{\alpha}_t}\right)\right)$$

$$= \exp\left(-\frac{1}{2}\left(\left(\frac{\alpha_t}{\beta_t} + \frac{1}{1-\bar{\alpha}_{t-1}}\right)x_{t-1}^2 - \left(\frac{2\sqrt{\alpha_t}}{\beta_t}\mathbf{x}_t + \frac{2\sqrt{\bar{\alpha}_{t-1}}}{1-\bar{\alpha}_{t-1}}x_0\right)x_{t-1} + C(x_t, x_0)\right)\right)$$

2. 扩散模型原理

➢ 反向过程

5. **因为前向分布都是高斯分布，所以$q(x_{t-1}|x_t,\ x_0)$也是高斯分布，求均值和方差就可以确定$q(x_{t-1}|x_t,\ x_0)$。**

$$q(x_{t-1}|x_t,\ x_0) \propto \exp\left(-\frac{1}{2}\left(\left(\frac{\alpha_t}{\beta_t}+\frac{1}{1-\bar{\alpha}_{t-1}}\right)x_{t-1}^2-\left(\frac{2\sqrt{\alpha_t}}{\beta_t}x_t+\frac{2\sqrt{\bar{\alpha}_{t-1}}}{1-\bar{\alpha}_{t-1}}x_0\right)x_{t-1}+C(x_t,\ x_0)\right)\right)$$

根据 $$\exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)=\exp\left(-\frac{1}{2}\left(\frac{1}{\sigma^2}x^2-\frac{2\mu}{\sigma^2}x+\frac{\mu^2}{\sigma^2}\right)\right)$$ (只是展开操作)

可得 方差 $\sigma^2=\frac{\beta_t(1-\alpha_{t-1})}{1-\alpha_t}$

均值 $\hat{\mu}_t(x_t,\ x_0)=\frac{\sqrt{\alpha_t}(1-\alpha_{t-1})}{1-\alpha_t}x_t+\frac{\sqrt{\alpha_{t-1}}\beta_t}{1-\alpha_t}x_0$ (2)

方差 σ^2 是常数，也可以变种预测方差

2. 扩散模型原理

➢ 反向过程

6. 可知$q(x_{t-1}|x_t,\ x_0)$方差是定值，对均值进行简化。

$$\text{均值}\ \hat{\mu}_t(\mathrm{x}_t, \mathrm{x}_0) = \frac{\sqrt{\alpha_t}(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t} x_t + \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1-\bar{\alpha}_t} x_0 \quad (2)$$

根据前向过程已知$x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{(1-\bar{\alpha}_t)}\check{\epsilon}_t$可得$x_0 = \frac{1}{\sqrt{\bar{\alpha}_t}}(x_t - \sqrt{(1-\bar{\alpha}_t)}\check{\epsilon}_t)$，

带入(2)式得

$$\hat{\mu}_t = \frac{1}{\sqrt{a_t}}\left(x_t - \frac{\beta_t}{\sqrt{1-\bar{a}_t}}\check{\epsilon}_t\right)$$

7. 因为根据前向传播进行计算化简的，这里的$\check{\epsilon}_t$是确定的对应前向扩散时的随机数$\check{\epsilon}_t$

x_t是已知的通过神经网络预测前向扩散的$\check{\epsilon}_t$，则可以确定$q(x_{t-1}|x_t,\ x_0)$

$$q(x_{t-1}|x_t,\ x_0) = \mathcal{N}\left(x_{t-1}; \frac{1}{\sqrt{a_t}}\left(x_t - \frac{\beta_t}{\sqrt{1-\bar{a}_t}}\check{\epsilon}_t\right), \frac{\beta_t(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t} I\right)$$

这里预测$\hat{\epsilon}_t$等效于在预测x_0，即已知x_t，x_0时的x_{t-1}分布，预测$\hat{\epsilon}_t$比预测x_0更简单。